



Hochschule für Technik und Wirtschaft Dresden

Fakultät Informatik/Mathematik

Bachelorarbeit

Thema:

Merkmalerkennung von Gebäuden und Grundstücken in Satellitenbildern mittels Deeplearning

Vorgelegt von: Sebastian Mischke
Dorfstraße 8, 01257 Dresden
geb. am 09.11.1995 in Dresden
Bibliotheksnummer: 37612

Studiengang: Medieninformatik

Externer Betreuer: Ann-Christin Storms
New Web Technology GmbH

Betreuender Prüfer: Prof. Dr. Marco Block-Berlitz

Zweitgutachter: Prof. Dr. Hans-Joachim Böhme

Letzte Änderung: 6. Juni 2017

Abgabetermin:

Inhaltsverzeichnis

1	Einleitung und Motivation	1
2	Konkretisierung der Aufgabenstellung	1
3	Stand der Technik	1
4	Gesamtplan	1
4.1	Satellitenbilder	1
4.2	Trainingsdaten	1
4.3	Künstliches neuronales Netz	1
5	Experimente	2
5.1	Postleitzahl	2
5.2	Solaranlagen	2
5.3	Schulen	2
6	Ergebnisse	2
7	Ausblick	2

Verzeichnis verwendeter Abkürzungen

Nomenclature

- API Eine Programmierschnittstelle, genauer Schnittstelle zur Anwendungsprogrammierung, häufig nur kurz API genannt (englisch application programming interface, wörtlich ‚Anwendungsprogrammierschnittstelle‘), ist ein Programmteil, der von einem Softwaresystem anderen Programmen zur Anbindung an das System zur Verfügung gestellt wird.
- MLP A multilayer perceptron (MLP) is a feedforward artificial neural network model that maps sets of input data onto a set of appropriate outputs. An MLP consists of multiple layers of nodes in a directed graph, with each layer fully connected to the next one. Except for the input nodes, each node is a neuron (or processing element) with a nonlinear activation function. MLP utilizes a supervised learning technique called backpropagation for training the network. MLP is a modification of the standard linear perceptron and can distinguish data that is not linearly separable.

Abbildungsverzeichnis

1	Datenflussdiagramm	1
2	Point Plot Beispiel	2

Zusammenfassung

Inhalt der Arbeit

1 Einleitung und Motivation

„Ein Bild sagt mehr als tausend Worte“. Doch gilt dies für alle Bilder? Und was sind das für Worte? Mit dem Aufkommen von Deeplearning und der hochwertigen Möglichkeiten der Bildanalyse eines Convolutional Neural Networks ist die Wissenschaft der Feature-Detection in den letzten Jahren weit vorangeschritten.

2 Konkretisierung der Aufgabenstellung

3 Stand der Technik

Im Projekt „PlaNet - Photo Geolocation with Convolutional Neural Networks“ konnte bereits gezeigt werden, dass ein Convolutional Neural Network in der Lage ist, den Aufnahmeort eines Fotos auf durchschnittlich 1200km genau zu bestimmen.

4 Gesamtplan

Das System zur Merkmalerkennung besteht aus drei Kernbausteinen. (siehe Abbildung 1)

- Den Satellitenbildern, die als Informationsgrundlage und Input-Daten für den Klassifizierer genutzt werden
- Dem künstlichen neuronalen Netz, welches die Input-Daten analysiert und klassifiziert
- Der Trainingsvorgabe, welche zum Trainieren des Netzes benutzt wird.

4.1 Satellitenbilder

Die Satellitenbilder bilden die Grundlage der Input-Daten für das Netz. Da eine eigenständige Erzeugung einen viel zu hohen Aufwand bedeuten würde, werden stattdessen Bilder verwendet, die mittels der Google Static Maps API erzeugt wurden. Dafür sind entweder die GPS-Koordinaten oder die Adresse des Grundstückes notwendig.

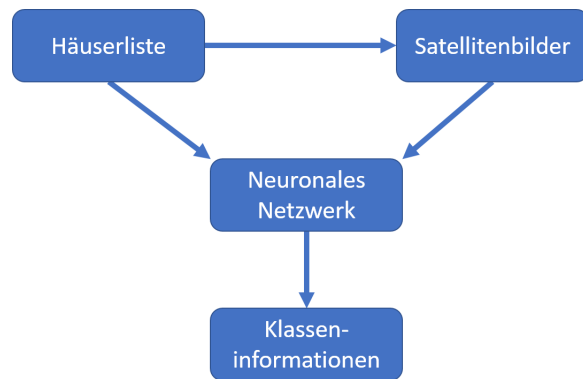


Abbildung 1: Datenflussdiagramm

Die Bilder werden lokal gespeichert und später zum Verarbeiten durch das Netz in 2D-Arrays für den Rot-, Blau, und Grün-Channel umgewandelt.

4.2 Trainingsdaten

Trainingsdaten geben dem Netz den gewünschten Output vor und werden dementsprechend zu diesem Training verwendet.

Das Erzeugen der Trainingsdaten ist in der Regel ein aufwändiger Prozess und stark vom gewünschten zu erkennenden Merkmal abhängig. Neben der großen Menge an Trainingsdaten, die zum Trainieren eines Netzes benötigt werden, sind manche Merkmale nicht leicht mit dem menschlichen Auge zu erkennen.

4.3 Künstliches neuronales Netz

Das neuronale Netz besteht es drei Teilen. Einem CNN, welches die Satellitenbilder als Input-Daten bekommt und diese auswertet, einem MLP, welches zusätzliche Metadaten des Gebäudes bzw. Grundstückes als Input-Daten bekommt, und einem MLP, welches die Output-Daten des CNN und des MLP als Input-Daten bekommt.

Nach jeder Trainingsepoche werden die Validierungsdaten vom Netz klassifiziert und die Ergebnisse mit der Trainingsvorlage verglichen. Der sich daraus ergebende Genauigkeitswert, auch Accuracy genannt, wird dann mit dem bisherigen Bestwert verglichen. Sollte die neue Accuracy besser sein als der bisherige Spitzenwert, so werden die Gewichte des Netzes gespeichert und der neue Bestwert wird sich gemerkt. dadurch soll ein Overfitting des Netzes vermieden werden.

```

1 def main():
2     # Load csv
3     X_train, Y_train = load_csv("
4         data.csv")
5     # Create net
6     model = create_net(X_train,
7         Y_train)
8     # Train net
9     history = model.fit(x=X_train, y
    =Y_train)
10    # Save net
11    save_model(model, "structure.
12        json", "weights.h5")

```

Literatur

5 Experimente

5.1 Postleitzahl




Abbildung 2: Point Plot Beispiel

5.2 Solaranlagen

5.3 Schulen

6 Ergebnisse

7 Ausblick